

Procesos Estocásticos: Sección 1

Alejandro Daniel José Gómez Flórez

1 Demostraciones

Teorema:

$$P^{(n)} = P^{(m)} \cdot P^{(n-m)}, \quad \text{en particular } P^{(n)} = P \cdot P \cdots P \text{ (} n \text{ veces)} = P^n.$$

Demostración:

Esta es la ecuación fundamental de Chapman-Kolmogorov que establece la propiedad multiplicativa de las matrices de transición. La demostraremos usando la definición probabilística y las propiedades de la esperanza condicional.

Notación: Sea $P_{ij}^{(n)}$ la probabilidad de transición del estado i al estado j en exactamente n pasos, es decir:

$$P_{ij}^{(n)} = \mathbb{P}(X_n = j \mid X_0 = i)$$

Demostración de la ecuación de Chapman-Kolmogorov:

Para demostrar que $P^{(n)} = P^{(m)} \cdot P^{(n-m)}$ donde $0 \leq m \leq n$, consideremos el elemento (i, j) de ambos lados.

Lado izquierdo: $P_{ij}^{(n)} = \mathbb{P}(X_n = j \mid X_0 = i)$

Lado derecho: $[P^{(m)} \cdot P^{(n-m)}]_{ij} = \sum_{k \in S} P_{ik}^{(m)} P_{kj}^{(n-m)}$

Usando la ley de probabilidad total condicionada en el estado en el tiempo m :

$$\begin{aligned} P_{ij}^{(n)} &= \mathbb{P}(X_n = j \mid X_0 = i) \\ &= \sum_{k \in S} \mathbb{P}(X_n = j, X_m = k \mid X_0 = i) \\ &= \sum_{k \in S} \mathbb{P}(X_n = j \mid X_m = k, X_0 = i) \cdot \mathbb{P}(X_m = k \mid X_0 = i) \end{aligned}$$

Por la propiedad de Markov, $\mathbb{P}(X_n = j \mid X_m = k, X_0 = i) = \mathbb{P}(X_n = j \mid X_m = k)$, ya que el futuro solo depende del estado presente, no del pasado.

Por lo tanto:

$$\begin{aligned} P_{ij}^{(n)} &= \sum_{k \in S} \mathbb{P}(X_n = j \mid X_m = k) \cdot \mathbb{P}(X_m = k \mid X_0 = i) \\ &= \sum_{k \in S} P_{kj}^{(n-m)} \cdot P_{ik}^{(m)} \\ &= \sum_{k \in S} P_{ik}^{(m)} P_{kj}^{(n-m)} \end{aligned}$$

Esto demuestra que $P_{ij}^{(n)} = [P^{(m)} \cdot P^{(n-m)}]_{ij}$ para todo i, j , por lo que:

$$P^{(n)} = P^{(m)} \cdot P^{(n-m)}$$

Caso particular: Para $P^{(n)} = P^n$, aplicamos inducción sobre n .

Caso base: $n = 1$: $P^{(1)} = P = P^1$ (correcto por definición)

Paso inductivo: Supongamos que $P^{(k)} = P^k$ para todo $k \leq n$. Entonces:

$$\begin{aligned} P^{(n+1)} &= P^{(n)} \cdot P^{(1)} \quad (\text{Chapman-Kolmogorov con } m = n) \\ &= P^n \cdot P \quad (\text{hipótesis inductiva}) \\ &= P^{n+1} \end{aligned}$$

Por inducción, $P^{(n)} = P^n$ para todo $n \geq 1$. □

Interpretación: La ecuación de Chapman-Kolmogorov nos dice que para ir del estado i al estado j en n pasos, podemos "hacer escala" en cualquier estado intermedio k en el tiempo m , y la probabilidad total es la suma sobre todos los posibles estados intermedios del producto de las probabilidades de los dos segmentos del viaje.

Teorema: Para una cadena de Markov con matriz de transición $P = (P_{ij})$:

- $\sum_{n=0}^{\infty} P_{ii}^{(n)} = \infty$ si, y solo si el estado i es recurrente
- $\sum_{n=0}^{\infty} P_{ii}^{(n)} < \infty$ si, y solo si el estado i es transitorio

Demostración:

Demostraremos ambas direcciones de la equivalencia.

Parte 1: (\Rightarrow) Si el estado i es recurrente, entonces $\sum_{n=0}^{\infty} P_{ii}^{(n)} = \infty$.

Sea N_i el número de veces que la cadena visita el estado i . Por definición:

$$N_i = \sum_{n=0}^{\infty} \mathbf{1}_{\{X_n=i\}}$$

Tomando esperanza condicionada en $X_0 = i$:

$$\mathbb{E}_i[N_i] = \mathbb{E}_i \left[\sum_{n=0}^{\infty} \mathbf{1}_{\{X_n=i\}} \right] = \sum_{n=0}^{\infty} \mathbb{E}_i[\mathbf{1}_{\{X_n=i\}}] = \sum_{n=0}^{\infty} P_{ii}^{(n)}$$

Si el estado i es recurrente, entonces la probabilidad de regresar a i partiendo de i es 1:

$$f_{ii} = \mathbb{P}_i(\text{regresar a } i \text{ alguna vez}) = 1$$

Esto implica que $\mathbb{E}_i[N_i] = \infty$ (visitamos i infinitas veces con probabilidad 1), por lo tanto:

$$\sum_{n=0}^{\infty} P_{ii}^{(n)} = \infty$$

Parte 2: (\Leftarrow) Si el estado i es transitorio, entonces $\sum_{n=0}^{\infty} P_{ii}^{(n)} < \infty$.

Si el estado i es transitorio, entonces $f_{ii} < 1$. Sea $q = 1 - f_{ii} > 0$ la probabilidad de nunca regresar a i partiendo de i .

El número de visitas a i sigue una distribución geométrica modificada. La probabilidad de visitar exactamente k veces el estado i es:

$$\mathbb{P}_i(N_i = k) = f_{ii}^{k-1} \cdot q = f_{ii}^{k-1} \cdot (1 - f_{ii})$$

Por lo tanto:

$$\begin{aligned} \mathbb{E}_i[N_i] &= \sum_{k=1}^{\infty} k \cdot f_{ii}^{k-1} \cdot (1 - f_{ii}) \\ &= (1 - f_{ii}) \sum_{k=1}^{\infty} k \cdot f_{ii}^{k-1} \\ &= (1 - f_{ii}) \cdot \frac{1}{(1 - f_{ii})^2} = \frac{1}{1 - f_{ii}} < \infty \end{aligned}$$

Como $\mathbb{E}_i[N_i] = \sum_{n=0}^{\infty} P_{ii}^{(n)}$ y $\mathbb{E}_i[N_i] < \infty$, concluimos que:

$$\sum_{n=0}^{\infty} P_{ii}^{(n)} < \infty$$

Conclusión: Hemos demostrado ambas direcciones:

- Estado recurrente $\Leftrightarrow \sum_{n=0}^{\infty} P_{ii}^{(n)} = \infty$
- Estado transitorio $\Leftrightarrow \sum_{n=0}^{\infty} P_{ii}^{(n)} < \infty$

□

Teorema: Si la cadena de Markov es irreducible y sus estados son recurrentes positivos, entonces la medida estacionaria π existe y es única. Además:

$$\pi_i = \frac{1}{m_i}, \quad i \in S$$

donde m_i es el **tiempo medio de retorno** al estado i , es decir,

$$m_i = E_i[T_i] \quad (\text{esperanza del tiempo hasta regresar a } i \text{ partiendo de } i)$$

Demostración:

Fijemos un estado $i \in S$. Consideremos los *ciclos de retorno* a i , definidos como las trayectorias que comienzan en i y terminan en la siguiente visita a i .

- La longitud de un ciclo tiene la misma distribución que T_i , por lo que la longitud media es m_i .
- En cada ciclo, el estado i es visitado exactamente una vez más (la visita de cierre). Por tanto, el número medio de visitas a i en un ciclo es 1.

Sea N_j el número de visitas al estado j en un ciclo. Definimos

$$\pi_j = \frac{E_i[N_j]}{m_i}$$

Esta definición nos da la fracción de tiempo que la cadena pasa en el estado j durante un ciclo típico que comienza en i .

Como la cadena es irreducible, todos los estados se comunican, y por tanto esta definición no depende del estado inicial i elegido. Además, se puede demostrar que:

1. $\sum_{j \in S} \pi_j = 1$ (normalización)
2. $\pi P = \pi$ (ecuación de balance)
3. $\pi_i = \frac{1}{m_i}$ para todo $i \in S$

La unicidad se sigue del hecho de que el sistema de ecuaciones $\pi P = \pi$ junto con la condición de normalización tiene una única solución cuando la cadena es irreducible y finita.

□

Teorema: Sea X_n una cadena de Markov $\{X_n\}_{n \geq 0}$ cuyos estados son irreducibles; recurrentes positivos y aperiódicos. Entonces:

$$\lim_{n \rightarrow \infty} P^n(x, y) = \pi(y)$$

Demostración:

La demostración se basa en el análisis del comportamiento asintótico de las potencias de la matriz de transición. Procederemos en varios pasos.

Paso 1: Existencia y unicidad de la distribución estacionaria

Por ser la cadena irreducible y recurrente positiva, sabemos del teorema anterior que existe una única distribución estacionaria π tal que $\pi P = \pi$ y $\sum_y \pi(y) = 1$.

Paso 2: Uso de la aperiodicidad

Como los estados son aperiódicos, para cada estado x existe un entero N_x tal que para todo $n \geq N_x$, se tiene $P^n(x, x) > 0$. Esto significa que es posible regresar al estado x en cualquier número suficientemente grande de pasos.

Paso 3: Acoplamiento y tiempo de mezcla

Definimos el *tiempo de acoplamiento* τ como el primer momento en que dos copias independientes de la cadena, iniciando desde estados diferentes, se encuentran en el mismo estado.

Para estados irreducibles, recurrentes positivos y aperiódicos, se puede demostrar que:

$$\mathbb{E}[\tau] < \infty$$

Paso 4: Convergencia en variación total

Sea $\mu_n^{(x)}$ la distribución de X_n dado $X_0 = x$. Entonces:

$$\mu_n^{(x)}(y) = P^n(x, y)$$

La distancia en variación total entre $\mu_n^{(x)}$ y π está dada por:

$$\|\mu_n^{(x)} - \pi\|_{TV} = \frac{1}{2} \sum_{y \in S} |P^n(x, y) - \pi(y)|$$

Paso 5: Demostración de la convergencia

Usando la técnica de acoplamiento, se puede demostrar que existe una constante $\rho < 1$ tal que:

$$\|\mu_n^{(x)} - \pi\|_{TV} \leq C\rho^n$$

para alguna constante $C > 0$. Esto implica convergencia exponencial.

En particular, para cada estado y :

$$|P^n(x, y) - \pi(y)| \leq 2\|\mu_n^{(x)} - \pi\|_{TV} \leq 2C\rho^n \rightarrow 0 \text{ cuando } n \rightarrow \infty$$

Por lo tanto:

$$\lim_{n \rightarrow \infty} P^n(x, y) = \pi(y)$$

Paso 6: Interpretación del resultado

Este teorema nos dice que, independientemente del estado inicial x , la probabilidad de estar en el estado y después de n pasos converge a $\pi(y)$ cuando $n \rightarrow \infty$. Esto significa que la cadena "olvida" su condición inicial y converge a su distribución de equilibrio.

La velocidad de convergencia es exponencial con tasa ρ , lo que hace que la convergencia sea relativamente rápida en la práctica.

□

Corolario: Si además la cadena es finita, entonces la convergencia es uniforme en el estado inicial:

$$\lim_{n \rightarrow \infty} \max_{x, y \in S} |P^n(x, y) - \pi(y)| = 0$$