

Profesor: Nicolás MORENO

Grupo: 01

11 de agosto de 2025.

Los métodos de Cadenas de Markov Monte Carlo (MCMC) son utilizado para simular valores de cierta densidad objetivo  $f$  cuya forma cerrada no sea conocida o simplemente no la podemos simular fácilmente. La estrategia de muestreo detrás del MCMC, es construir una cadena de Markov irreducible y aperiódica cuya distribución estacionaria sea la función objetivo  $f$ . Esto es, para un  $t$  suficientemente grande, una realización  $X_t$  de esta cadena tendrá una distribución cercana a  $f$  y además

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n h(X_i) = \mathbf{E}_f(h(X))$$

lo cual obviamente nos permite aproximar integrales (por eso Monte Carlo en el nombre del método).

**Problema 1.** Para ejemplificar esto, defina la siguiente cadena de Markov  $x_t = \beta x_{t-1} + \varepsilon_t$ , donde  $\varepsilon_t$  es una secuencia iid con distribución normal(0,1). Realice simulaciones de  $x_t$  con  $\beta = 0,1$  para obtener que la distribución estacionaria es normal(0,  $1/(1 - \beta^2)$ ). Justifique muy bien la conclusión anterior, utilizando métodos gráficos y test.

Existen varias estrategias para construir la cadena de Markov cuya distribución estacionaria coincida con  $f$ , una de ellas es el algoritmo de Metropolis-Hasting. Dada una función objetivo  $f$ , se le asocia una densidad  $q(x|y)$  la cual, en la practica, sea más fácil de simular. El soporte de la función  $q(\cdot|y)$  debe contener el soporte de  $f$ .

---

**Algoritmo 1:** Metropolis-Hasting

---

1. Simule  $Y_t \sim q(y|x_t)$

2. Tome

$$X_{t+1} = \begin{cases} Y_t & \text{con probabilidad } \rho(x_t, Y_t) \\ x_t & \text{con probabilidad } 1 - \rho(x_t, Y_t) \end{cases}$$

$$\text{donde } \rho(x, y) = \min \left\{ \frac{f(y)q(x|y)}{f(x)q(y|x)}, 1 \right\}$$

---

**Problema 2.** Utilizando el algoritmo anterior. Simule variables aleatorias de una Beta(2,6). Realice comprobaciones gráficas y aplique tests apropiados.

El esquema bayesiano se puede explicar de la siguiente manera. Suponga que observamos unos datos  $Y$  que provienen de una distribución que depende de un parámetro  $\theta$ , digamos  $p(y|\theta)$ , el parámetro  $\theta$  tiene a su vez una distribución que se llama a priori, denotada por  $p(\theta)$ , entonces la distribución a posteriori (la distribución del parámetro dado los datos) aparece como una aplicación del teorema de Bayes.

$$p(\theta|y) = \frac{p(\theta)p(y|\theta)}{p(y)}$$

Es en este contexto donde el algoritmo Metropolis-Hasting es comúnmente utilizado para samplear desde la distribución  $p(\theta|y)$ . Naturalmente, la función de densidad a priori se puede utilizar como la función candidata  $q(\cdot|y)$  de nuestro algoritmo.

**Problema 3.**

- Simule (sin usar MCMC) una muestra aleatoria de tamaño 100 de la siguiente mezcla de distribuciones.

$$(1 - \alpha) \cdot \text{normal}(\mu = 8, \sigma = 5) + \alpha \cdot \text{student-t}(\mu = 10, \nu = 3)$$

donde  $\alpha = 0,7$ ,  $\mu$  es el parámetro de centralidad y  $\nu$  son grados de libertad .

- Utilizando la data simulada en el punto anterior y suponiendo que  $\alpha$  tiene una distribución a priori Beta(1, 1) y Beta(2, 10) simule una muestra desde la distribución a posteriori utilizando el algoritmo Metropolis-Hasting y estime  $\mathbf{E}(\theta|y)$  para ambas a prioris.

**Entregables:** Un breve informe que fundamente la respuestas a la preguntas planteadas y un archivo de texto con los algoritmos (R o MATLAB)

**Fecha de entrega:** Martes 19 de agosto antes de las 23h59. En el buzón habilitado